

Adekwatność reprezentacji i przenośne profile relacyjne

Badania omiczne mierzą jednocześnie aktywność tysięcy genów lub innych cząsteczek u każdego pacjenta. Jednym z głównych celów analizy jest odnalezienie grup osób o podobnych mechanizmach choroby. Wynik takiego grupowania silnie zależy jednak od sposobu porównywania pacjentów. Możemy porównywać bezpośrednio wartości pomiarów albo pytać, które geny mają u danego pacjenta wyższą aktywność niż inne. Drugi sposób prowadzi do prostych reguł, na przykład „gen A jest bardziej aktywny niż gen B”. Takie reguły mogą być łatwiejsze do interpretacji i mniej zależne od skali laboratoryjnej, ale nie zawsze są lepsze.

Celem projektu jest ustalenie, kiedy każdy z tych sposobów porównywania jest uzasadniony, a następnie opracowanie przenośnych relacyjnych profili pacjentów tam, gdzie wspierają je dane. Najpierw program, korzystając wyłącznie z jednej kohorty źródłowej, sprawdzi wartości, rangi, relacje między genami i połączenie tych informacji. Jeżeli żadna reprezentacja nie daje wiarygodnej struktury, program będzie mógł uczciwie wstrzymać grupowanie. Dla stabilnych grup utworzy krótkie profile złożone z relacji między cechami. Taki profil będzie pełnił rolę czytelного opisu grupy, zamiast sztucznego „średniego pacjenta”.

Pełny profil zostanie następnie zamrożony i zastosowany do pacjentów z niezależnych kohort. Dane nowych pacjentów nie będą służyły do ponownego uczenia, wspólnej normalizacji ani poprawiania progów. Pacjent zostanie przypisany tylko wtedy, gdy wystarczająco wiele reguł będzie można sprawdzić, a wynik będzie jednoznaczny. W przeciwnym razie pozostanie bez przypisania. To ważna cecha: niepewność nie będzie ukrywana przez wymuszenie decyzji.

Badania obejmą kontrolowane symulacje oraz niezależne kohorty raka płuca i raka jelita grubego. We wszystkich podstawowych porównaniach różne sposoby opisu pacjentów będą korzystały z tego samego deterministycznego algorytmu grupowania. Ocenimy stabilność, długość i czytelność profili, pokrycie genów między platformami, odporność na zakłócenia oraz zgodność zamrożonych grup z informacją biologiczną i kliniczną. Etykiety choroby i wyniki kliniczne będą używane dopiero na końcu, wyłącznie do oceny.

Wyniki wstępne pokazują, że różne reprezentacje rzeczywiście działają najlepiej w różnych warunkach. Pokazały też ważne ograniczenie: stabilna struktura nie musi odpowiadać konkretnej etykietce klinicznej, a jeden z dwóch kierunków transferu między kohortami nie spełnił z góry ustalonego kryterium. Projekt nie zakłada więc, że relacje zawsze wygryją. Jego wynikiem będą metody i jawne zasady określające, kiedy relacyjne profile pacjentów są wiarygodne, kiedy należy zachować informacje o wartościach, a kiedy uczciwym wynikiem jest rezygnacja z grupowania.